

# A História e o Desenvolvimento Técnico dos Grandes Modelos de Linguagem: Dos N-gramas ao Aprendizado em Contexto

## RESUMO (TL;DR)

Como são construídos: os LLMs modernos são redes neurais Transformer (Vaswani et al., 2017) treinadas em duas a três etapas — pré-treinamento autossupervisionado para prever o próximo token em trilhões de tokens de texto, seguido por ajuste fino supervisionado e aprendizado por reforço a partir de feedback humano (RLHF) para torná-los utilizáveis — com tokenização (codificação por pares de bytes), o mecanismo de autoatenção e leis de escala derivadas empiricamente como pilares técnicos centrais.

Como começou: o campo evoluiu da teoria da informação de Shannon (1948) e dos modelos estatísticos de n-gramas da IBM/Jelinek (décadas de 1970-80), passando pelo modelo neural probabilístico de linguagem de Bengio et al. (2003) e pelos embeddings de palavras (word2vec 2013, GloVe 2014), até o Transformer (2017) e os primeiros LLMs propriamente ditos — GPT-1 (2018), BERT (2018), GPT-2 (2019) e GPT-3 (2020).

O primeiro grande salto: o avanço arquitetural mais citado é o Transformer de 2017, mas o momento em que os LLMs deram um salto qualitativo de capacidade de aprendizado foi o GPT-3 (2020), que demonstrou que escalar para 175 bilhões de parâmetros produzia aprendizado em contexto/few-shot — a capacidade de aprender novas tarefas a partir de um prompt sem atualizar os pesos — um comportamento formalizado pelas leis de escala de Kaplan et al. (2020), posteriormente refinado pelo Chinchilla (2022) e tornado utilizável pelo InstructGPT/RLHF (2022).

## PRINCIPAIS DESCOBERTAS

- O Transformer foi o ponto de inflexão arquitetural. “Attention Is All You Need” (Vaswani et al., NeurIPS 2017, arXiv:1706.03762) substituiu a recorrência pela autoatenção, tornando o treinamento massivamente paralelizável e possibilitando a escala necessária a todos os LLMs posteriores. Segundo uma análise da Nature de abril de 2025, é o sétimo artigo mais citado do século XXI, com mais de 173.000 citações em 2025.
- O LLM como o conhecemos é uma história de escala construída sobre uma receita de pré-treinamento. GPT-1 (Radford et al., 2018) estabeleceu pré-treinamento generativo + ajuste fino; BERT (Devlin et al., 2018) demonstrou o pré-treinamento bidirecional; GPT-2 (2019) mostrou capacidade multitarefa zero-shot com escala; GPT-3 (2020) demonstrou aprendizado few-shot em contexto.
- As leis de escala transformaram a construção de modelos em uma ciência de engenharia. Kaplan et al. (2020) mostraram que a perda diminui segundo uma lei de potência suave em função dos parâmetros, dos dados e do compute; Hoffmann et al. (2022, “Chinchilla”) corrigiram a razão ótima de dados/parâmetros para aproximadamente 20 tokens por parâmetro.
- O “salto” possui duas interpretações defensáveis, e as evidências favorecem o aprendizado em contexto do GPT-3 como o salto de capacidade — enquanto RLHF/InstructGPT (2022) foi o salto de usabilidade/alinhamento que produziu o ChatGPT.
- “Capacidades emergentes” são cientificamente controversas. Wei et al. (2022) argumentaram que certas capacidades aparecem subitamente em escala; Schaeffer et al. (2023, vencedor do prêmio Outstanding Paper da NeurIPS) argumentaram que boa parte desse fenômeno é um artefato de métricas descontínuas.

## DETALHES

### 1. Precursores: modelagem estatística de linguagem (1948-década de 2000)

A tarefa fundamental de todos os modelos de linguagem — atribuir probabilidades a sequências de palavras ou, de forma equivalente, prever a próxima palavra — remonta à aplicação da teoria da informação de Claude Shannon à linguagem em 1948, que introduziu aproximações por n-gramas do inglês e o conceito de entropia. A abordagem foi industrializada nas décadas de 1970 e 1980 por Frederick Jelinek e colegas do Thomas J. Watson Research Center da IBM (e, independentemente, por James Baker na CMU), que utilizaram modelos probabilísticos de n-gramas em sistemas de reconhecimento de fala e introduziram os termos “modelo de linguagem” e “perplexidade” como medida informacional da incerteza de um modelo (Jelinek 1976; Bahl et al. 1983).

Um modelo de n-gramas assume uma hipótese de Markov: a probabilidade de uma palavra depende apenas das  $n-1$  palavras anteriores. Esses modelos foram bem-sucedidos, mas sofreram com a maldição da dimensionalidade e a esparsidade dos dados — a maioria das possíveis sequências de palavras nunca é observada durante o treinamento — exigindo técnicas de suavização (add-one/Laplace, Good-Turing, Katz backoff). Notavelmente, essa abordagem estatística e empírica substituiu a objeção teórica anterior de Chomsky de que processos de Markov de estados finitos eram modelos inadequados da linguagem.

## **2. A virada neural: representações distribuídas (2003-2015)**

A mudança conceitual decisiva veio com “A Neural Probabilistic Language Model” (JMLR, 2003), de Yoshua Bengio, Réjean Ducharme, Pascal Vincent e Christian Jauvin. A ideia central era combater a maldição da dimensionalidade aprendendo uma representação distribuída para palavras — mapeando cada palavra para um vetor contínuo — de modo que “cada sentença de treinamento [pudesse] informar o modelo sobre um número exponencial de sentenças semanticamente vizinhas”. Uma rede neural feed-forward com uma única camada oculta aprendia conjuntamente os vetores das palavras e a função de probabilidade. Essa é a ancestral arquitetural direta dos LLMs modernos.

Essa ideia tornou-se prática e popular com o word2vec (Mikolov, Chen, Corrado e Dean, “Efficient Estimation of Word Representations in Vector Space”, ICLR 2013, arXiv:1301.3781), que introduziu as arquiteturas computacionalmente baratas Continuous Bag-of-Words (CBOW) e Skip-gram. Como afirma o resumo do artigo, “leva menos de um dia e uma CPU para derivar vetores de alta qualidade de 300 dimensões para um milhão de palavras a partir de um conjunto de dados de 1,6 bilhão de palavras”. O word2vec ficou famoso por capturar regularidades linguísticas como aritmética vetorial (rei – homem + mulher  $\approx$  rainha).

O GloVe (Pennington, Socher e Manning, EMNLP 2014), de Stanford, ofereceu uma abordagem complementar baseada em contagem e coocorrência global, alcançando 75% em uma tarefa de analogias de palavras. Esses embeddings estáticos — um vetor por palavra, independentemente do contexto — tornaram-se a camada de entrada da próxima geração de modelos.

Outro precursor essencial foi a linha de trabalho de sequência-para-sequência (seq2seq) com atenção em tradução automática neural. Sutskever, Vinyals e Le (2014) e Cho et al. (2014) introduziram o codificador-decodificador RNN/LSTM, que comprimia uma sentença de origem em um único vetor de tamanho fixo. Bahdanau, Cho e Bengio (2014/2015, “Neural Machine Translation by Jointly Learning to Align and Translate”) identificaram esse vetor de tamanho fixo como um gargalo e introduziram o mecanismo de atenção — permitindo ao decodificador focar dinamicamente nas partes relevantes da origem. Essa “atenção aditiva/Bahdanau” foi a semente conceitual direta do Transformer.

## **3. O avanço arquitetural: o Transformer (2017)**

“Attention Is All You Need” (Vaswani, Shazeer, Parmar, Uszkoreit, Jones, Gomez, Kaiser, Polosukhin; arXiv:1706.03762, 12 de junho de 2017; NeurIPS 2017), do Google Brain/Google Research, é o artigo arquitetural mais importante do campo. Sua mudança radical foi eliminar completamente recorrência e convoluções e construir o modelo apenas com autoatenção.

A importância técnica: a autoatenção permite que cada token preste atenção a todos os outros tokens da sequência simultaneamente, usando a fórmula de produto escalar escalado  $\text{Attention}(Q, K, V) = \text{softmax}(QK^T/\sqrt{d_k})V$ . Isso captura dependências de longo alcance diretamente, em vez de transmitir informação passo a passo por uma cadeia recorrente.

**Paralelização:** como os tokens são processados ao mesmo tempo, o treinamento pode ser paralelizado ao longo da dimensão da sequência, reduzindo drasticamente o tempo de treinamento e — criticamente — permitindo a escala que define os LLMs. RNNs, em contraste, tinham um gargalo sequencial inerente.

**Atenção multi-head:** o Transformer original usava 8 cabeças, cada uma com dimensão  $d_k = d_v = d_{\text{model}}/h = 64$ , permitindo ao modelo atender simultaneamente a informações de diferentes subespaços de representação.

**Resultado empírico:** o Transformer grande alcançou novo estado da arte de 28,4 BLEU no WMT 2014 inglês-alemão (melhoria de mais de 2 BLEU sobre o melhor resultado anterior, incluindo ensembles) e 41,8 BLEU em inglês-francês, após apenas 3,5 dias de treinamento em 8 GPUs NVIDIA P100 — uma fração do custo dos modelos de estado da arte anteriores.

O Transformer original era um codificador-decodificador para tradução. Os LLMs modernos no estilo GPT usam a variante apenas-decoder, com geração autoregressiva (da esquerda para a direita, com máscara causal); modelos no estilo BERT usam a variante apenas-encoder.

## **4. Os primeiros LLMs: a revolução do pré-treinamento (2018-2019)**

Dois artigos de 2018 estabeleceram o paradigma “pré-treinar e depois adaptar” que define os LLMs:

**GPT-1:** “Improving Language Understanding by Generative Pre-Training” (Radford, Narasimhan, Salimans, Sutskever; OpenAI, 2018). Um Transformer decoder de 12 camadas com 117 milhões de parâmetros, demonstrou pré-treinamento generativo em texto não rotulado seguido de ajuste fino discriminativo para cada tarefa, com transformações de entrada específicas da tarefa exigindo pouca alteração arquitetural. Obteve ganhos como +8,9% em raciocínio de senso comum (Stories Cloze) e +5,7% em perguntas e respostas (RACE). Foi o primeiro modelo a aplicar um Transformer pré-treinado a uma ampla gama de tarefas de PLN.

**BERT:** “Pre-training of Deep Bidirectional Transformers for Language Understanding” (Devlin, Chang, Lee, Toutanova; Google AI, arXiv:1810.04805, 2018). O BERT usou o encoder do Transformer e introduziu modelagem de linguagem mascarada (previsão de tokens aleatoriamente mascarados usando tanto o contexto à esquerda quanto à direita), além da previsão da próxima sentença. Elevou o benchmark GLUE para 80,5 (melhoria absoluta de 7,7 pontos), o MultiNLI para 86,7% e o SQuAD v1.1 F1 para 93,2, estabelecendo novo estado da arte em onze tarefas de PLN. O BERT demonstrou o poder do pré-treinamento bidirecional para tarefas de compreensão e tornou-se o paradigma dominante de ajuste fino.

**GPT-2:** “Language Models are Unsupervised Multitask Learners” (Radford, Wu, Child, Luan, Amodei, Sutskever; OpenAI, 2019). Escalando em 10× a receita do GPT-1 para 1,5 bilhão de parâmetros e treinando em aproximadamente 40 GB de texto (WebText, 8 milhões de páginas da web coletadas de links do Reddit com alto karma), o GPT-2 demonstrou transferência zero-shot de tarefas — realizando tradução, sumarização e perguntas e respostas sem treinamento específico para a tarefa — e alcançou estado da arte em 7 de 8 conjuntos de dados de modelagem de linguagem em cenário zero-shot. Também provocou o primeiro grande debate sobre segurança e liberação de IA, pois a OpenAI inicialmente reteve o modelo completo. O GPT-2 consolidou a hipótese de escala: capacidades qualitativamente novas podem surgir simplesmente ao escalar um objetivo de previsão da próxima palavra.

## **5. O salto de capacidade: GPT-3 e aprendizado em contexto (2020)**

GPT-3: “Language Models are Few-Shot Learners” (Brown et al., OpenAI, arXiv:2005.14165; NeurIPS 2020) é o artigo catalisador da era moderna dos LLMs. Ele treinou um Transformer autoregressivo com 175 bilhões de parâmetros (mais de 100× maior que o GPT-2). O artigo afirma: “Todos os modelos foram treinados por um total de 300 bilhões de tokens”.

O avanço científico foi o **<b>aprendizado em contexto (ICL)</b>**: o GPT-3 conseguia realizar uma nova tarefa simplesmente ao receber alguns exemplos em seu prompt — sem atualizações de gradiente e sem ajuste fino. O artigo avaliou três regimes: zero-shot (somente instrução), one-shot (uma demonstração) e few-shot (normalmente 10-100 demonstrações que coubessem na janela de contexto). A descoberta empírica decisiva, ilustrada pelos resultados agregados em 42 benchmarks, foi que, enquanto o desempenho zero-shot melhora continuamente com o tamanho do modelo, o desempenho few-shot melhora mais rapidamente — demonstrando que modelos maiores são mais proficientes em aprendizado em contexto. Em outras palavras, escala não apenas adicionou conhecimento; ela melhorou a própria adaptabilidade do modelo.

**<b>Por que isso foi considerado um grande salto:</b>** rompeu o paradigma dominante de “pré-treinar e depois ajustar em um conjunto de dados rotulado por tarefa”. Um único modelo congelado podia agora realizar tradução, QA, aritmética e desembaralhamento apenas a partir de prompts.

Isso sugeriu que um preditor de próximo token suficientemente grande executa implicitamente uma forma de meta-aprendizado — inferindo a tarefa a partir do contexto do prompt. Trabalhos teóricos posteriores (por exemplo, Xie et al. 2021) formalizaram o ICL como uma forma de inferência bayesiana.

Isso tornou o “prompt” a principal interface para IA, definindo o padrão de interação de todos os produtos posteriores.

## **6. Por que a escala funciona: leis de escala (2020) e Chinchilla (2022)**

A base empírica do salto do GPT-3 são as “Scaling Laws for Neural Language Models” (Kaplan, McCandlish, Henighan, Brown, Chess, Child, Gray, Radford, Wu, Amodei; OpenAI, arXiv:2001.08361, janeiro de 2020). Os autores descobriram que a perda de entropia cruzada escala segundo uma lei de potência suave em três variáveis — parâmetros do modelo  $N$ , tamanho do conjunto de dados  $D$  e computação  $C$  — com tendências abrangendo mais de sete ordens de magnitude, e que detalhes arquiteturais (largura, profundidade) importavam relativamente pouco em comparação.

A recomendação era: para um orçamento computacional fixo, treinar modelos muito grandes com dados relativamente modestos e interromper antes da convergência, porque modelos maiores são mais eficientes em termos de amostras. O artigo transformou o desenvolvimento de modelos em uma disciplina de engenharia previsível e motivou diretamente a aposta no tamanho do GPT-3.

“Training Compute-Optimal Large Language Models” (Hoffmann et al., DeepMind, arXiv:2203.15556, março de 2022) — o artigo “Chinchilla” — corrigiu a recomendação de Kaplan. O resumo relata que, ao treinar mais de 400 modelos de linguagem, variando de 70 milhões a mais de 16 bilhões de parâmetros e de 5 a 500 bilhões de tokens, os autores descobriram que, para treinamento ótimo em termos de computação, o tamanho do modelo e a quantidade de tokens de treinamento devem ser escalados igualmente: para cada duplicação do tamanho do modelo, o número de tokens de treinamento também deve dobrar — uma razão de aproximadamente 20 tokens por parâmetro.

Isso significava que a maioria dos LLMs existentes (incluindo GPT-3, com menos de 2 tokens por parâmetro) estava significativamente subtreinada. Eles validaram isso treinando o Chinchilla (70B parâmetros em 1,4 trilhão de tokens), que superou de maneira uniforme e significativa Gopher (280B), GPT-3 (175B), Jurassic-1 (178B) e Megatron-Turing NLG (530B) em uma ampla variedade de tarefas de avaliação, alcançando média de 67,5% no benchmark MMLU, mais de 7% acima do Gopher, além de ser mais barato na inferência. A lei paramétrica da perda  $L(N,D) = E + A/N^\alpha + B/D^\beta$  tornou-se uma formulação padrão. Uma sutileza observada posteriormente pelo campo: o Chinchilla revisitou os expoentes de Kaplan com taxas de aprendizado melhor ajustadas em diferentes escalas, descobrindo que a escala anterior havia sido confundida por hiperparâmetros mal ajustados. Modelos modernos como Llama rotineiramente “super-treinam” muito além da razão 20:1 por razões econômicas de inferência.

## **7. O salto de usabilidade: ajuste por instruções e RLHF (2022)**

Um LLM pré-treinado bruto prevê continuações plausíveis de texto, mas não segue instruções de forma confiável nem se alinha consistentemente à intenção do usuário. A ponte para assistentes utilizáveis foi “Training Language Models to Follow Instructions with Human Feedback” (Ouyang et al., OpenAI,

arXiv:2203.02155, março de 2022) — o artigo do InstructGPT. Ele formalizou o pipeline de RLHF em três etapas:

1. **Ajuste fino supervisionado (SFT):** ajustar o modelo pré-treinado com demonstrações escritas por humanos do comportamento desejado.
2. **Treinamento do modelo de recompensa:** coletar classificações humanas das saídas do modelo e treinar um modelo de recompensa para prever preferências humanas.
3. **Aprendizado por reforço:** otimizar o modelo SFT em relação ao modelo de recompensa usando Proximal Policy Optimization (PPO) (Schulman et al., 2017).

O resultado principal forneceu evidência marcante de que alinhamento importa mais que tamanho bruto para utilidade: as saídas do InstructGPT de 1,3 bilhão de parâmetros foram preferidas por avaliadores humanos às do GPT-3 de 175 bilhões de parâmetros — apesar de terem 100× menos parâmetros — ao mesmo tempo em que melhoraram a veracidade e reduziram saídas tóxicas, com regressões mínimas nos benchmarks padrão de PLN. Essa metodologia sustentou diretamente o ChatGPT (novembro de 2022) e hoje é padrão nos principais laboratórios, com variantes como DPO e RLAIIF.

## 8. Capacidades emergentes — e o debate científico

Um salto alegado distinto é o fenômeno das capacidades emergentes. Em “Emergent Abilities of Large Language Models” (Wei et al., Transactions on Machine Learning Research / arXiv:2206.07682, junho de 2022), uma capacidade é definida como emergente “se não estiver presente em modelos menores, mas estiver presente em modelos maiores”, de modo que “não possa ser prevista simplesmente extrapolando o desempenho de modelos menores”. Exemplos incluíam aritmética multi-etapas, desembaralhamento de palavras e QA multilíngue, que permaneciam próximos ao acaso até um limiar de escala (frequentemente  $\sim 10^{22}$  FLOPs de treinamento ou  $\sim 100B$  parâmetros), e então saltavam.

Um resultado relacionado é o prompting por cadeia de pensamento (CoT) (Wei et al., “Chain-of-Thought Prompting Elicits Reasoning in Large Language Models”, arXiv:2201.11903, NeurIPS 2022), no qual pedir ao modelo que produza etapas intermediárias de raciocínio melhora dramaticamente o raciocínio — e esse benefício também surgiu apenas em escala (por exemplo, um modelo de 540B parâmetros com oito exemplos CoT alcançou estado da arte no benchmark matemático GSM8K, superando um GPT-3 ajustado com um verificador).

O contraponto científico é importante. Em “Are Emergent Abilities of Large Language Models a Mirage?” (Schaeffer, Miranda, Koyejo; Stanford; arXiv:2304.15004; NeurIPS 2023 Outstanding Main Track Paper Award), os autores argumentam que a emergência é frequentemente um artefato da escolha da métrica, e não uma mudança fundamental do modelo. A tese é que, para uma tarefa e família de modelos específicas, capacidades emergentes podem aparecer devido à escolha da métrica pelos pesquisadores, enquanto métricas lineares ou contínuas produzem mudanças suaves, contínuas e previsíveis.

O argumento técnico: a perda de entropia cruzada por token cai suavemente com a escala. Uma métrica descontínua, como correspondência exata de string ou avaliação de múltipla escolha — que exige que todos os tokens estejam corretos — comprime geometricamente ganhos suaves por token em um salto aparentemente abrupto e “imprevisível”. Formalmente, se a acurácia por token  $p$  aumenta suavemente, a acurácia de uma sequência inteira é aproximadamente  $p^L$  (para uma resposta de  $L$  tokens), produzindo uma aparente transição de fase, enquanto a distância de edição dos tokens  $\approx L \cdot (1-p)$  revela a melhoria suave subjacente.

Evidências: em aritmética no GPT-3/InstructGPT, mudar a métrica ou coletar mais dados de teste removeu a emergência; no BIG-Bench, mais de 92% das capacidades emergentes alegadas ocorreram sob apenas duas métricas (Multiple Choice Grade e Exact String Match), e apenas cerca de 5 de 39 métricas mostraram emergência. Na família LaMDA, a emergência sob a métrica descontínua Multiple Choice Grade desapareceu quando os resultados foram recalculados com o Brier score contínuo. Os autores até produziram emergência aparente em redes de visão (CNNs no MNIST e autoencoders no CIFAR100) escolhendo métricas descontínuas.

Crucialmente, os autores não afirmam que emergência seja impossível — apenas que algumas capacidades emergentes anteriormente alegadas parecem ser miragens induzidas pelas análises dos

pesquisadores. Esse é o principal debate científico em aberto sobre se a escala produz transições qualitativas genuínas de fase ou um progresso suave obscurecido pelas métricas.

## 9. O pipeline moderno completo de treinamento (resumo técnico)

1. **Coleta e curadoria de dados:** reunir um corpus massivo (trilhões de tokens) de rastreamentos da web (por exemplo, Common Crawl / C4), livros, código e Wikipedia; depois filtrar por qualidade, deduplicar e remover contaminação de benchmarks.
2. **Tokenização:** converter texto bruto em tokens de subpalavras usando codificação por pares de bytes (BPE) — um algoritmo de compressão (Gage, 1994) adaptado para PLN por Sennrich, Haddow e Birch (ACL 2016, “Neural Machine Translation of Rare Words with Subword Units”), que mescla iterativamente os pares de símbolos adjacentes mais frequentes. Isso lida elegantemente com palavras raras e fora do vocabulário ao decompô-las em subunidades conhecidas. O GPT-2 introduziu BPE em nível de bytes (um vocabulário base de 256 bytes capaz de representar qualquer texto).
3. **Pré-treinamento:** treinar um Transformer apenas-decoder com objetivo autossupervisionado de previsão do próximo token (perda de entropia cruzada) sobre o corpus, usando leis de escala para alocar o orçamento computacional entre tamanho do modelo e dados. É aqui que a maior parte da computação é gasta e onde o conhecimento de mundo e a competência linguística são adquiridos.
4. **Ajuste fino supervisionado (instruction tuning):** ajustar o modelo com demonstrações selecionadas de instrução-resposta para que ele adote um formato de assistente.
5. **Alinhamento por preferências (RLHF/DPO):** treinar um modelo de recompensa com classificações de preferências humanas e otimizar a política (via PPO ou Direct Preference Optimization) para ser útil, inofensiva e honesta.
6. **Adaptação durante a inferência:** implantar com aprendizado em contexto (exemplos few-shot) e estratégias de prompting como chain-of-thought — sem exigir novas atualizações dos pesos.

## RECOMENDAÇÕES

Para um leitor que queira realmente compreender tanto o “como” quanto o “como começou”, recomenda-se a seguinte trilha de leitura, nesta ordem:

1. **Comece pelo levantamento para obter o mapa.** Leia Zhao et al., “A Survey of Large Language Models” (arXiv:2303.18223, 2023) para ter uma visão completa, dos modelos estatísticos aos neurais e aos modelos pré-treinados. Combine com Speech and Language Processing, de Jurafsky & Martin (Capítulo 3 sobre n-gramas), para as bases pré-neurais.
2. **Leia os artigos primários em ordem cronológica** para perceber a progressão intelectual: Bengio et al. 2003 → word2vec (2013) → Bahdanau et al. (2014) → Vaswani et al. 2017 (o essencial) → GPT-1 (2018) e BERT (2018) → GPT-2 (2019) → GPT-3 (2020, o salto de capacidade) → Kaplan et al. (2020) → Chinchilla (2022) → InstructGPT (2022).
3. **Para entender o “primeiro grande salto”,** concentre a leitura aprofundada em dois artigos: Attention Is All You Need (o habilitador arquitetural) e Language Models are Few-Shot Learners (o salto de capacidade). Se for necessário escolher um único “momento”, a resposta honesta é que 2017 (Transformer) foi o avanço habilitador e 2020 (aprendizado em contexto do GPT-3) foi o avanço de capacidade — são respostas complementares, não concorrentes.
4. **Enfrente a controvérsia, não a ignore.** Leia Wei et al. (2022) sobre capacidades emergentes e a réplica de Schaeffer et al. (2023) em conjunto. Compreender esse debate é a melhor maneira de desenvolver uma avaliação calibrada sobre o que a escala faz e o que ela não faz.

## AVALIAÇÕES QUE MUDARIAM ESTA CONCLUSÃO

Trabalhos futuros que demonstrassem definitivamente (a) saltos genuínos e descontínuos de capacidade em escala, independentes da métrica (validando uma emergência forte), ou (b) que arquiteturas

diferentes do Transformer escalam de maneira comparável, mudariam o enquadramento sobre “qual foi o salto”. Com as evidências atuais, o pipeline Transformer + escala + RLHF continua sendo a explicação consensual.

## RESSALVAS

<b>“Primeiro LLM” depende da definição.</b> Não existe um limiar universalmente aceito a partir do qual um “modelo de linguagem” se torna “grande”. Especialistas razoáveis podem indicar GPT-1/BERT (2018, primeiros Transformers pré-treinados), GPT-2 (2019, primeiro em escala de aproximadamente um bilhão de parâmetros com generalidade zero-shot) ou GPT-3 (2020, o modelo que popularizou o termo “LLM”). Este relatório trata o GPT-3 como o momento de cristalização, ao mesmo tempo em que reconhece seus predecessores.

<b>O “salto” é genuinamente controverso e depende parcialmente da ênfase.</b> Avanços arquiteturais (2017), de capacidade (2020) e de usabilidade (2022) são todos “saltos” defensáveis. A posição adotada aqui é que o aprendizado em contexto do GPT-3 foi o salto decisivo de capacidade de aprendizado, mas isso é um julgamento interpretativo, não um fato estabelecido.

<b>A emergência continua sendo uma questão científica em aberto.</b> O debate Wei vs. Schaeffer permanece sem resolução; leitores devem tratar com ceticismo apropriado alegações fortes de saltos súbitos e imprevisíveis de capacidade.

<b>Algumas fontes secundárias não são acadêmicas.</b> Quando possível, as afirmações foram fundamentadas nos artigos primários de arXiv/conferências (NeurIPS, ACL/EMNLP, JMLR, TMLR). Posts de blogs, artigos do Medium e sites explicativos foram usados apenas para orientação e checados contra fontes primárias; as contagens de citações mencionadas incidentalmente mudam com o tempo.

<b>Os números evoluem.</b> Contagens de parâmetros, tokens e resultados BLEU/benchmarks são extraídos dos artigos originais; observe que a OpenAI posteriormente corrigiu algumas contagens de parâmetros do GPT-2, e números de estado da arte em benchmarks são rapidamente superados.

<b>Escopo.</b> Este relatório se concentra na linhagem de LLMs de texto e não aborda em profundidade os desenvolvimentos paralelos em modelos multimodais, arquiteturas mixture-of-experts, retrieval-augmented generation (RAG) ou a era pós-2023 de modelos de raciocínio, pois esses temas estão fora do escopo de “origens e primeiro salto” da consulta.